

# 1 Classification

1. Derive the dual formulation of the soft support vector machine algorithm.

## Solution of T1

软间隔SVM原始问题:

最小化:

$$\frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i$$

满足约束:

$$y_i(w \cdot x_i + b) \geq 1 - \xi_i, \xi_i \geq 0$$

设  $\alpha_i \geq 0, \mu_i \geq 0$ , 构造拉格朗日函数:

$$L(w, b, \xi, \alpha, \mu) = \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i - \sum_{i=1}^n \alpha_i [y_i(w^T x_i + b) - 1 + \xi_i] - \sum_{i=1}^n \mu_i \xi_i$$

对  $w$ 、 $b$ 、 $\xi_i$  求偏导:

$$\frac{\partial L}{\partial w} = w - \sum_{i=1}^n \alpha_i y_i x_i = 0 \Rightarrow w = \sum_{i=1}^n \alpha_i y_i x_i$$

$$\frac{\partial L}{\partial b} = - \sum_{i=1}^n \alpha_i y_i = 0 \Rightarrow \sum_{i=1}^n \alpha_i y_i = 0$$

$$\frac{\partial L}{\partial \xi_i} = C - \alpha_i - \mu_i = 0 \Rightarrow \alpha_i = C - \mu_i$$

代入拉格朗日对偶函数,

$$\begin{aligned}
\mathcal{G}(\alpha, \mu) &= \min_{w, b, \xi} L(w, b, \xi, \alpha, \mu) \\
&= \frac{1}{2} \left\| \sum_{i=1}^n \alpha_i y_i x_i \right\|^2 + C \sum_{i=1}^n \xi_i \\
&\quad - \sum_{i=1}^n \alpha_i [y_i (\sum_{j=1}^n \alpha_j y_j x_j^T x_i + b) - 1 + \xi_i] - \sum_{i=1}^n \mu_i \xi_i \\
&= \frac{1}{2} \left( \sum_{i=1}^n \alpha_i y_i x_i \right)^T \cdot \left( \sum_{j=1}^n \alpha_j y_j x_j \right) \\
&\quad - \sum_{i=1}^n \alpha_i [y_i (\sum_{j=1}^n \alpha_j y_j x_j^T x_i + b) - 1] \\
&= \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j - \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j \\
&\quad - b \sum_{i=1}^n \alpha_i y_i + \sum_{i=1}^n \alpha_i \\
&= \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j
\end{aligned}$$

从而得到对偶问题：

$$\max_{\alpha, \mu} \mathcal{G}(\alpha, \mu) = \max_{\alpha} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j x_i^T x_j$$

约束条件为：

$$\sum_{i=1}^n \alpha_i y_i = 0, \quad 0 \leq \alpha_i \leq C, \quad i = 1, \dots, n$$

2. Derive the Discriminant function of the Quadratic Discriminant Analysis.

## Solution of T2

QDA假设对于每一个类别k，其特征向量x服从多元高斯分布：

$$p(x|Y = k) = \frac{1}{(2\pi)^{p/2} |\Sigma_k|^{1/2}} \exp \left( -\frac{1}{2} (x - \mu_k)^T \Sigma_k^{-1} (x - \mu_k) \right)$$

记 $\pi_k = P(Y = k)$ ，由Bayes，后验概率为：

$$P(Y = k|x) = \frac{\pi_k p(x|Y = k)}{\sum_{l=1}^K \pi_l p(x|Y = l)}$$

决策规则为：

$$\begin{aligned}
\hat{Y} &= \arg \max_k P(Y = k|x) \\
&= \arg \max_k \frac{\pi_k p(x|Y = k)}{\sum_{l=1}^K \pi_l p(x|Y = l)}
\end{aligned}$$

取对数并忽略常数项：

$$\hat{Y} = \arg \max_k -\frac{1}{2}(x - \mu_k)^T \Sigma_k^{-1}(x - \mu_k) - \frac{1}{2} \log |\Sigma_k| + \log \pi_k$$

从而导出了QDA的判别函数

$$\delta_k(\mathbf{x}) = -\frac{1}{2}(\mathbf{x} - \mu_k)^T \Sigma_k^{-1}(\mathbf{x} - \mu_k) - \frac{1}{2} \log |\Sigma_k| + \log \pi_k$$

3. Derive the Gaussian process classifier by using the Laplace approximation.

### Solution of T3

对分类问题而言，观测目标  $y_i \in \{0, 1\}$  离散，高斯噪声模型  $y_i = f(x_i) + \epsilon_i$  不再适用。因此引入潜函数  $f(\mathbf{x})$ ，并利用链接函数(通常为sigmoid函数)将其映射到概率。

为潜函数赋予一个高斯过程先验:

$$p(\mathbf{f}|X) = \mathcal{N}(\mathbf{f}|\mathbf{0}, K)$$

其中  $K_{ij} = k(\mathbf{x}_i, \mathbf{x}_j)$ 。

给定潜函数  $\mathbf{f}$ ， $\mathbf{y}$ 是伯努利随机变量构成的随机向量

$$p(\mathbf{y}|\mathbf{f}) = \prod_{i=1}^n p(y_i|f_i) = \prod_{i=1}^n \sigma(f_i)^{y_i} (1 - \sigma(f_i))^{1-y_i}$$

要求潜函数的后验分布  $p(\mathbf{f}|X, \mathbf{y})$  ,根据Bayes:  $p(\mathbf{f}|X, \mathbf{y}) = \frac{p(\mathbf{y}|\mathbf{f})p(\mathbf{f}|X)}{p(\mathbf{y}|X)}$

分母为正则化项。由于  $p(\mathbf{y}|\mathbf{f})$  非高斯，因此考虑拉普拉斯近似。以下求解近似分布  $q(\mathbf{f}|X, \mathbf{y})$

先求后验分布的众数  $\hat{\mathbf{f}}$ 。对后验分布取对数，得到：

$$\hat{\mathbf{f}} = \arg \max_{\mathbf{f}} [\log p(\mathbf{y}|\mathbf{f}) + \log p(\mathbf{f}|X)]$$

定义  $\Psi(\mathbf{f}) \triangleq \log p(\mathbf{y}|\mathbf{f}) + \log p(\mathbf{f}|X)$

其中

$$\log p(\mathbf{f}|X) = -\frac{1}{2}\mathbf{f}^\top K^{-1}\mathbf{f} - \frac{1}{2} \log |K| - \frac{n}{2} \log 2\pi$$

$$\log p(\mathbf{y}|\mathbf{f}) = \sum_{i=1}^n [y_i \log \sigma(f_i) + (1 - y_i) \log(1 - \sigma(f_i))]$$

所以，

$$\Psi(\mathbf{f}) = \log p(\mathbf{y}|\mathbf{f}) - \frac{1}{2}\mathbf{f}^\top K^{-1}\mathbf{f} + \text{const.}$$

令  $\nabla \Psi(\mathbf{f}) = \mathbf{0}$ ,  $\nabla \Psi(\mathbf{f}) = \nabla \log p(\mathbf{y}|\mathbf{f}) - K^{-1}\mathbf{f}$

其中， $\nabla \log p(\mathbf{y}|\mathbf{f})$  的第*i*个分量为：

$$\frac{\partial}{\partial f_i} \log p(\mathbf{y}|\mathbf{f}) = y_i - \sigma(f_i)$$

因此，

$$\nabla \Psi(\mathbf{f}) = (\mathbf{y} - \boldsymbol{\sigma}) - K^{-1}\mathbf{f}$$

其中  $\boldsymbol{\sigma} = [\sigma(f_1), \dots, \sigma(f_n)]^T$ 。从而可以反解出众数  $\hat{\mathbf{f}}$ 。

以下计算众数处的Hessian矩阵以进行Laplace近似。

$$\nabla \nabla \Psi(\mathbf{f}) = \nabla \nabla \log p(\mathbf{y}|\mathbf{f}) - K^{-1}$$

其中  $\nabla \nabla \log p(\mathbf{y}|\mathbf{f})$  是一个对角矩阵，其对角线元素为：

$$\frac{\partial^2}{\partial f_i^2} \log p(y_i|f_i) = \frac{\partial}{\partial f_i} (y_i - \sigma(f_i)) = -\sigma(f_i)(1 - \sigma(f_i))$$

所以，在众数  $\hat{\mathbf{f}}$  处，Hessian矩阵为：

$$H = \nabla \nabla \Psi(\hat{\mathbf{f}}) = -\hat{W} - K^{-1}$$

其中  $\hat{W}$  是对角阵， $\hat{W}_{ii} = \sigma(\hat{f}_i)(1 - \sigma(\hat{f}_i))$ 。从而近似分布  $q(\mathbf{f}|X, \mathbf{y}) = \mathcal{N}(\mathbf{f}|\hat{\mathbf{f}}, \Sigma)$ ，其中协方差矩阵  $\Sigma = (-H)^{-1} = (\hat{W} + K^{-1})^{-1}$ 。

对于预测点  $\mathbf{x}_*$ ，下求其分类标签  $y_*$ 。

由高斯过程的性质， $\mathbf{f}$  和  $f_*$  的联合先验是高斯分布：

$$\begin{bmatrix} \mathbf{f} \\ f_* \end{bmatrix} \sim \mathcal{N}\left(\mathbf{0}, \begin{bmatrix} K & \mathbf{k}_* \\ \mathbf{k}_*^\top & k_{**} \end{bmatrix}\right)$$

其中  $\mathbf{k}_* = [k(\mathbf{x}_1, \mathbf{x}_*), \dots, k(\mathbf{x}_n, \mathbf{x}_*)]^\top$ ， $k_{**} = k(\mathbf{x}_*, \mathbf{x}_*)$ 。

则  $f_*$  的预测分布为：

$$q(f_*|X, \mathbf{y}, \mathbf{x}_*) = \int p(f_*|X, \mathbf{x}_*, \mathbf{f}) q(\mathbf{f}|X, \mathbf{y}) d\mathbf{f} = \mathcal{N}(f_*|\mu_*, \sigma_*^2)$$

其中  $\mu_* = \mathbf{k}_*^\top K^{-1} \hat{\mathbf{f}}$ ， $\sigma_*^2 = k_{**} - \mathbf{k}_*^\top (K + \hat{W}^{-1})^{-1} \mathbf{k}_*$

预测概率如下(各项参数见上方表达式)：

$$P(y_* = 1|X, \mathbf{y}, \mathbf{x}_*) = \int \sigma(f_*) q(f_*|X, \mathbf{y}, \mathbf{x}_*) df_*$$

4. For the following data, build a tree by using: a) Gini index, b) the depth of tree is two. The target variable is **Loan Approved**.

## Solution of T4

首先计算每个特征的Gini

### 1. Age

取中位数37为分割节点，分成  $\leq 37$ ,  $> 37$  两类。

左侧有10个样本，3个Yes，7个No。

$$Gini_L = 1 - ((3/10)^2 + (7/10)^2) = 0.42$$

右侧有10个样本，10个Yes，0个No。

$$Gini_R = 0$$

$$\text{加权 } Gini_{split} = \frac{10}{20} \times 0.42 + \frac{9}{20} \times 0.1975 = 0.21$$

### 2. Income

取分割点50000，分成  $\leq 50000$ ,  $> 50000$  两类。

左侧有10个样本，3个Yes，7个No。

$$Gini_L = 1 - ((3/10)^2 + (7/10)^2) = 0.42$$

右侧有10个样本，10个Yes，0个No。

$$Gini_R = 0$$

$$\text{加权 } Gini_{split} = \frac{10}{20} \times 0.42 = 0.21$$

### 3. Credit Score

取分割点650，分成  $\leq 650$ ,  $> 650$  两类。

左侧有7个样本，0个Yes，7个No。

$$Gini_L = 0$$

右侧有13个样本，13个Yes，0个No。

$$Gini_R = 0$$

$$\text{加权 } Gini_{split} = 0$$

故节点选择Credit Score ( $\leq 650$  vs  $> 650$ ), Gini=0, 已经达到最小。所以只能将根节点看成第1层，从而得到深度为2的树。

5. For the data set in <https://archive.ics.uci.edu/dataset/17/breast+cancer+wisconsin+diagnostic>, try following algorithms learned in the class: a) Discriminate function (mse, ppn, svm); b) Generative method (LDA, QDA, Naive Bayes (Gaussian)); c) logistic regression, neural network; d) KNN, tree method, random forest, e): kernel method (kernel svm, Gaussian process classifier). Report the parameters of your algorithm, and the accuracy on the test set.

## Solution of T5

[Linear Regression] Accuracy = 0.9766

[Perceptron] Accuracy = 0.9649

max\_iter=1000, tol=1e-3, random\_state=42

[Linear SVM] Accuracy = 0.9649

kernel='linear', C=1.0, random\_state=42

[LDA] Accuracy = 0.9649

[QDA] Accuracy = 0.9415

[GaussianNB] Accuracy = 0.9415

[Logistic Regression] Accuracy = 0.9825

C=1.0, solver='lbfgs', max\_iter=1000

[Neural Network MLP] Accuracy = 0.9649

hidden\_layer\_sizes=(50,25), activation='relu', solver='adam', max\_iter=1000, random\_state=42

[KNN] Accuracy = 0.9649

n\_neighbors=5

[Decision Tree] Accuracy = 0.9006

max\_depth=5, random\_state=42

[Random Forest] Accuracy = 0.9708

n\_estimators=100, max\_depth=5, random\_state=42

[RBF SVM] Accuracy = 0.9825

kernel='rbf', C=1.0, gamma='scale', random\_state=42

[Gaussian Process Classifier] Accuracy = 0.9825

kernel=kernel, random\_state=42